

列车优化操纵速度模式曲线 生成的智能计算研究^{*}

金炜东 靳 蕃 李崇维 胡 飞 苟先太
(西南交通大学 成都)

提 要 讨论了在起伏坡道线路上运行的列车节能操纵的优化计算问题,给出了一种局部优化与全局优化相配合的计算结构,用以生成列车优化操纵的速度模式曲线。以仿真计算获得局部优化规律,用神经网络实现局部优化规律的数据组织,应用遗传算法进行全局优化计算,获得了令人满意的结果。

关键词 列车优化操纵 节能 优化 遗传算法 神经网络

中图分类号 U 284

Study on Intelligent Computation of Velocity Schema Curve of Optimization Operation for Train

Jian Weidong Jin Fan Li Chongwei Hu Fei Gou Xiantai
(Institute of Electrical Engineering, Southwest Jiaotong University, Chengdu 610031, China)

Abstract In this paper, the optimization computation problem of saving energy for the train travelling on the undulating slope line is discussed. To generate the velocity schema curve of optimization operation for train, a computation model combined local optimization with global optimization is proposed. The local optimization numerical functions are obtained from the simulation computation and the construction of those datum is realized by neural network. The global optimization computation using genetic algorithm generates the velocity schema curve. The result is satisfactory.

Keywords optimization operation for train; energy saving; optimization; genetic algorithm; neural network

列车优化操纵问题的研究,既可用于建立司机操纵指导系统,也是研究列车自动驾驶的基础工作,在技术和经济方面都有重要意义。世界上许多国家以及我国的铁路科技工作者以多种形式相继开展了一些这方面的研究工作^[1]。其中一类重要的工作是建立司机操纵实时指导系统。在微型机环境下建立的司机操纵指导系统,指导司机操纵的直观方式是给出列车优化操纵的速度模式曲线,即在给定列车运行条件下的“路程—速度”曲线。

^{*} 国家自然科学基金资助项目(No.69574026)

收稿日期:1998-02-23 金炜东 男 1959 年出生 教授 西南交通大学电气工程学院 邮编:610031

根据实际背景问题,我们研究了在安全正点前提下列车节能操纵的优化计算问题。列车节能操纵问题的数学模型是一个非线性有约束的动态最优化问题。在无法求得最优解的情况下,通过仿真计算可获得优化的数值规律。而对于实时优化计算,目前有效的方法是离线仿真优化结合在线实时计算以获得可行的满意解。由于该优化计算问题相当复杂,实际上往往只能根据一些节能原则在一定范围内进行仿真优化计算。这就要求实时优化计算模型具有大范围全局优化的信息处理能力。有效的优化策略和数据组织结构、离线仿真优化的计算精度和在线实时计算模型的信息处理能力,构成了统一的优化计算模型的有效性和适应能力。在借鉴了已有的优化方法并分析了其中的不足之处,我们提出的优化计算模型的结构是,将整个优化问题分解成局部优化和全局优化两部分;以离线仿真优化计算获得局部优化的数值规律,以神经网络实现局部优化规律的映射关系,作为在线实时信息处理的基础数据;用遗传算法进行全局优化计算,生成列车优化操纵的速度模式曲线。文献[1]介绍了这一优化模型的基本框架。本文在文献[1]的基础上,进一步重点讨论生成列车优化操纵速度模式曲线的智能计算问题。

1 生成速度模式曲线的计算结构

列车在起伏坡道线路上运行,其节能的优化操纵序列比较复杂。对于这种情况下列车节能操纵的优化计算,文献[1]介绍了我们提出的一种寻优策略。列车在由“上坡一下坡(包括若干平道)”构成的一个起伏坡道上运行,由节能原则给出优化的操纵序列形式。通过仿真优化计算得出在优化操纵下通过某个起伏坡道时列车耗能与运行时间的关系。将列车运行区间划分为 N 个子区间,每个典型子区间为一个起伏坡道。于是,列车在整个运行区间上节能操纵的优化问题可描述为

$$\min E = \sum_{i=1}^N E_i \tag{1}$$

$$E_i = g_i(T_i, V_{in}(i)) \tag{2}$$

$$V_{out}(i) = \Phi(T_i, V_{in}(i)) \tag{3}$$

$$\sum_{i=1}^N T_i = T \tag{4}$$

式中, $i=1, \dots, N$, 为子区间序号; $V_{in}(i)$ 、 $V_{out}(i)$ 分别为各子区间的入口速度和出口速度,有 $V_{in}(1)=0, V_{out}(N)=0, V_{in}(i+1)=V_{out}(i)$; T 为给定的区间运行时间^[1]。

以某一实际线路列车运行的仿真计算为例加以说明。
算例:运行区间长为 22.417 km, 给定运行时间 $T=27$ min。线路共分 52 个断面, 划分为 5 个子区间。仿真优化计算给出式(2)和式(3)表示的数值函数关系^[1]。 $E_1=g_1(T_1, V_{in}(1))=g_1(T_1, 0)$ 和 $V_{out}(1)=\Phi(T_1, V_{in}(1))=\Phi(T_1, 0)$ 均为一根曲线, 分别由图 1 和图 2 所示。对于 $i=2, 3, 4, 5$ 时的 $E_i=g_i(T_i, V_{in}(i))$ 和 $i=2, 3, 4$ 时的 $V_{out}(i)=\Phi(T_i, V_{in}(i))$, 则分别对应于不同的 $V_{in}(i)$ 给出了一组曲线。图 3 和图 4 分别给出了 $E_4=g_4(T_4, V_{in}(4))$ 和 $V_{out}(4)=\Phi(T_4, V_{in}(4))$ 两组曲线, 对应于 $V_{in}(4)=0, 4, 8, \dots, 76$ km/h, 各为 20 条曲线。(其余几组曲线, 数值不同, 情况类似。)

可给出列车节能操纵的速度模式曲线生成的优化计算结构为:
(1) 将列车运行区间划分为 N 个子区间, 每个子区间是一个起伏坡道。第一个和第 N 个




图 1 算例的 $E_1 = g_1(T_1, 0)$ 函数值




图 2 算例的 $V_{out}(1) = \Phi(T_1, 0)$ 函数值




图 3 算例的 $E_4 = g_4(T_4, V_{in}(4))$ 函数值




图 4 算例的 $V_{out}(4) = \Phi(T_4, V_{in}(4))$ 函数值

子区间可能只是一个起伏坡道的一部分。对于给定的列车编组,通过仿真优化计算得出列车通过每个子区间时的数值函数关系: $E_i = g_i(T_i, V_{in}(i))$, $(i = 1, \cdots, N)$, 和 $V_{out}(i) = \Phi(T_i, V_{in}(i))$, $(i = 1, \cdots, N - 1)$, 即式(2)和式(3)。这一步完成了局部优化计算。

(2) 训练神经网络,学习式(2)和式(3)描述的上述各组数值函数关系。用神经网络实现函数映射 $(T_i, V_{in}(i)) \rightarrow E_i$, $(i = 1, \cdots, N)$ 和 $(T_i, V_{in}(i)) \rightarrow V_{out}(i)$, $(i = 1, \cdots, N - 1)$ 。即以神经网络实现局部优化规律的数据组织。

(3) 在式(2)和式(3)描述的反映局部优化规律的各组数值函数的基础上,利用神经网络实现的局部优化规律函数映射关系的计算网络,应用遗传算法进行全局优化计算,即在约束 $\sum_{i=1}^N T_i = T$ 下,计算 $\min E = \sum_{i=1}^N E_i$ 。

(4) 根据全局优化的结果,可得到在 $E = \min E$ 时各子区间运行时间的优化分配 T_i ($i = 1, \cdots, N$)。由 T_i ($i = 1, \cdots, N$) 根据仿真优化计算可得到列车在各子区间上的优化操纵序列,由此确定列车在运行区间上各点的速度,给出“路程—速度”曲线,即为优化的列车节能操纵速度模式曲线。

2 局部优化规律的数据组织

在神经网络的研究热潮中,BP(Backpropagation)网络是应用最为广泛的学习网络。BP网络是一种多层前馈型网络。当隐含层节点数可根据需要自由增加时,一个三层前馈型网络实现的映射可以一致逼近紧集上的连续函数,或按 L_2 范数逼近紧集上平方可积的函数。BP网络有着丰富的映射能力,并提供了有效的学习算法。对于给定的输入—输出关系(样本),通过训练可使BP网络实现通过这些样本点的一个映射^[2,3]。对于由仿真优化计算获得的以式(2)和式

(3) 形式给出的局部优化规律,我们应用 BP 网络实现这些数值函数的映射关系,以这种计算网络形式为全局优化计算提供了快速的数据组织结构。

对应于式(2) 描述的函数关系, $i=1$ 时, $V_{in}(1)=0$, BP 网络的学习样本为 (T_1^k, E_1^k) ; 对于 $i=2, \dots, N$, 其学习样本为 $((T_i^k, V_{in}^k(i)), E_i^k)$ 。对应于式(3), $i=1$ 时 BP 网络的学习样本为 $(T_1^k, V_{out}^k(1))$; 对于 $i=2, \dots, N-1$, 其学习样本为 $((T_i^k, V_{in}^k(i)), V_{out}^k(i))$ 。 $i \neq 1$ 时的映射关系分别为两个输入 $(T_i, V_{in}(i))$ 对应于一个输出 $(E_i$ 或 $V_{out}(i))$ 。

反映局部优化规律的式(2) 和式(3) 的数值函数关系, 数据量较大。例如本文中所给出的算例, $i \neq 1$ 时的 $E_i = g_i(T_i, V_{in}(i))$ 和 $V_{out}(i) = \Phi(T_i, V_{in}(i))$ 各为 20 条曲线, 每条曲线又由数量不等的数据点构成。这意味着 BP 网络的学习样本集较大。理论分析和仿真实验都表明, 样本规模对 BP 算法的学习复杂性影响很大, 并且学习样本集越大, 学习误差也越大^[4,5]。在用 BP 网络实现连续值函数的逼近时, 降低学习误差的问题也更加突出。因此, 在用 BP 网络实现式(2) 和式(3) 的函数映射关系的计算中, 对学习样本数据采取了如下处理办法:

(1) 对于 $i \neq 1$ 时的各子区间, 学习样本由 $E_i = g_i(T_i, V_{in}(i))$ 和 $V_{out}(i) = \Phi(T_i, V_{in}(i))$ 的 n_i 条曲线提供。将这 n_i 条曲线(曲线 1 至曲线 n_i) 的数据分成 l 组: 第 1 组为曲线 1 至曲线 n_1 , 第 2 组为曲线 n_1 至曲线 n_2 , $\dots$, 第 l 组为曲线 n_{l-1} 至曲线 n_l 。用 l 个 BP 网络(BP 网络 1, $\dots$, BP 网络 l) 分别实现这 l 组(第一组, $\dots$, 第 l 组) 的函数映射关系。各组数据间存在重叠部分(即第 j 组数据的第一条曲线(曲线 n_{j-1}) 亦是第 $j-1$ 组数据的最后一条曲线), 是为了由 BP 网络组成的计算网络在进行非样本点的映射计算时实现的是内部插值行为。

(2) 将二维输入空间 $(T_i, V_{in}(i))$ 扩展为四维输入空间 $(T_i, T_i, V_{in}(i), V_{in}(i))$, 以增强网络的映射能力。例如, 在对原输入数值进行了归一化处理后, 即已通过 $x = \frac{x^0 - x_{min}}{x_{max} - x_{min}}$ 的方式(其中 x_{max} 和 x_{min} 分别为归一化处理前的变量 x^0 的最大值和最小值), 将 T_i 和 $V_{in}(i)$ 的数值压缩为 $T_i \in [0, 1]$, $V_{in} \in [0, 1]$, 可将增加的辅助输入 T_i 和 $V_{in}(i)$ 定义为

$$T_i = \begin{cases} 0, & T_i < 0.5 \\ 1, & T_i \geq 0.5 \end{cases} \quad V_{in}(i) = \begin{cases} 0, & V_{in}(i) < 0.5 \\ 1, & V_{in}(i) \geq 0.5 \end{cases}$$

经过这样处理之后, 显著改善了 BP 网络的学习效果。对于本文中所给的算例, 经试验后选择的三层 BP 网络的结构为: 输入层 4 个神经元, 隐含层 9 个神经元, 输入




图 5 计算 E_i 或 $V_{out}(i)$ 的计算网络结构

层 1 个神经元, 简称为“4-9-1”BP 网络。实现式(2) 和式(3) 的函数映射关系, 对于 $i=1$ 时的 $E_1 = g_1(T_1, V_{in}(1))$ 和 $V_{out}(1) = \Phi(T_1, V_{in}(1))$, 分别用一个 BP 网络即可。对于 $i=2, 3, 4, 5$ 时的 $E_i = g_i(T_i, V_{in}(i))$ 和 $i=2, 3, 4$ 时的 $V_{out}(i) = \Phi(T_i, V_{in}(i))$, 分别用多个“4-9-1”BP 网络来完成。学习训练完成后实现其函数映射关系的计算网络结构如图 5 所示。

图 1 和图 2 中分别标出了 $i=1$ 时局部优化规律仿真优化计算给出的数据(标以 $\circ$ 的点) 和由此样本用 BP 网络计算给出的数据(标以 $\times$ 的点)。

3 遗传算法用于全局优化计算

遗传算法(GA Genetic Algorithms) 是一种基于自然选择原理和群体遗传机理的搜索(优化) 算法。它模拟自然界中的生命进化机制, 在人工系统中实现特定目标的优化。GA 将所求问题的解用编码串(染色体) 来表示, 每个染色体代表一个解, 并形成一组代表优化问题的可能解的集合(种群) 。以适应值反映优化目标。根据各个个体对环境的适应度(适应值大小) , 将遗传算子作用于种群, 即按照“适者生存”原则对种群中的各个染色体随机进行“选择、交叉、变异”等遗传操作, 生成新的种群。反复迭代, 最终获得含有已知最优个体(对应于搜索到的最优解) 的总体适应值较高的优良种群, 实现优化目标的搜索。GA 的寻优方式不同于一般的搜索方法。GA 处理参数空间的编码而不是参数本身; 其搜索过程是从一组解迭代到另一组解, 可降低陷入局部极值点的可能性; GA 只利用目标函数值的信息进行搜索, 不必用到目标函数的导数等辅助信息; GA 使用随机变换规则指导搜索而不是确定性规则。GA 的寻优特点使其广泛应用于许多领域。近年来 GA 的研究受到普遍关注, 成为一个跨学科的研究热点^[6~9]。

对于已给出局部优化规律的列车节能操纵的全局优化问题, 很适合采用 GA 进行全局优化计算。优化目标, 是使 $E \rightarrow \min E$ 。要求的解, 是在 $E = \min E$ 时优化分配的各子区间运行时间 $T_i (i = 1, \dots, N)$ 的值。这是一个有约束的优化问题。

对于这类有约束优化问题的求解, 文献[10]给出了一种改进的遗传算法。该改进 GA 采用模拟编码。交叉操作采用各个基因片断(每个基因片断对应于一个参数) 同时分别进行交叉的多节点并行交叉方式, 并设置了动态改变的交叉基始值。变异操作采用设计一个环境串作用到染色体的模拟码串上的方式实现。算法设计中采用在目标函数中施加惩罚项的方式将有约束问题转化成等效的无约束问题用 GA 进行寻优搜索。仿真实验表明, 该改进 GA 对于这类优化问题有效地提高了搜索效率, 改善了优化效果。

采用该改进 GA 进行列车节能操纵的全局优化计算。对于本文算例, 算法中具体设计为:

(1) 染色体编码: $t = \{t_1, \dots, t_N\}$ 。其中, $N = 5$; $t_1, \dots, t_5$ 分别为 5 个子区间的运行时间, $t = \sum_{i=1}^5 t_i$ 为整个运行区间的总的运行时间。

(2) 惩罚项 p : 设 T 为给定的整个运行区间的总的运行时间, 对于每个染色体 t , 如 $|T - t| \leq \Delta T$, 则 $p = 1$ 否则 $p = C |T - t| / T + 1$ 式中, Δ 是设定的允许误差时间, C 为一个常数。

(3) 适应值 f : 对于每个染色体 $t = \{t_1, \dots, t_5\}$, 根据其中的每个参数 $t_1, \dots, t_5$, 由 BP 网络建立的各子区间的局部优化规律的函数关系计算得出相应的耗能 $e_1, \dots, e_5$, 则该染色体 t 的耗能 $e = \sum_{i=1}^5 e_i$, 给出其适应值 f 为

$$f = -e \cdot p \tag{5}$$

可见: 能耗 e 越小, 适应值 f 越大; 如果 $|T - t| > \Delta T$, 则 $p > 1$, 使得其适应值 f 较小。

其他参数设置为: 种群规模为 50; 每个染色体由 5 个参数组成, 每个参数的编码长度为 9, 对应的编码范围为 0~511。经过 80 代的进化迭代之后给出的一次优化计算结果为 $\{T_1, T_2,$

$T_3, T_4, T_5\} = \{205.64, 274.44, 545.71, 346.09, 247.97\}(\text{s})$, 总的运行时间 $T = \sum_{i=1}^5 T_i =$

1 619.85 s(给定运行时间为 27 min=1 620 s)。进化迭代的优化过程如图 6 所示。根据优化结果给出的五个子区间优化分配的运行时间 $\{T_1, T_2, T_3, T_4, T_5\}$ 及相应的优化操纵序列,通过仿真计算可给出速度模式曲线,如图 7 所示。

4 结束语

列车优化操纵速度模式曲线的生成,是建立列车优化操纵司机指导系统的核心工作,其计算问题对实时性要求较高。本文介绍的优化计算模型及相应的局部优化与全局优化相结合的计算结构,应用了神经网络和遗传算法等智能计算技术,较好地兼顾了优化计算的时效性及对环境状态(计算参数)变化的适应性与优化计算精度的要求。以离线方式进行局部优化规律的仿真计算,注重计算精度。用神经网络实现局部优化规律的映射关系,并具有良好的数据归纳(泛化)能力,为全局优化计算中的数据处理提供了快速的数据结构。应用改进的遗传算法进行全局优化计算获得了良好的优化效果,可以满足实时性要求获得优化的满意解。仿真结果说明了本文计算模型的有效性。

本文的优化计算模型虽然是以列车节能操纵为优化目标给出的,然而实际上对于以其他综合指标为优化目标的列车优化操纵问题,其优化计算问题如无本质区别,本文的计算方法也提供了有效途径。

5 参考文献

1 金炜东等.列车节能操纵优化方法研究.铁道学报,1997;19(6)
2 靳蕃等.神经网络与神经计算机.成都:西南交通大学出版社,1991
3 应行仁,曾南.多层神经网络的样本记忆能力.计算机学报,1992;(2)
4 张铃,张钊.神经网络中 BP 算法的分析.模式识别与人工智能,1994;7(3)
5 穆志纯等.利用双 BP 算法提高 BP 网络的泛化能力.模式识别与人工智能,1995;8(1)
6 Goldberg D E.Genetic algorithm in search, optimization and machine learning. MA: Addison Wesley, 1989
7 Davis L.Handbook of genetic algorithms. New York: Van Nostrand Reinhold, 1991
8 谢金星.进化计算简要综述.控制与决策,1997;12(1)
9 孙艳丰,王众托.遗传算法在优化问题中的应用研究进展.控制与决策,1996;11(4)
10 苟先太,金炜东.有约束优化中遗传算法的应用.西南交通大学学报,1997;32(4)




图 6 GA 优化过程的耗能变化曲线




图 7 根据优化结果仿真计算给出的速度模式曲线